Previsão de Preços de Imóveis Utilizando Regressão Linear: Um Estudo com o Conjunto de Dados de Preços de Habitação

Lucas Fortolan Sampaio
Graduando em Engenharia da Computação
Fundação Hermínio Ometto
Araras, Brasil
lucas.fortolan@alunos.fho.edu.br

***Resumo*—Este trabalho apresenta um estudo sobre a aplicação de regressão linear para prever o preço de casas a partir de suas características estruturais e de localização. Foram realizadas etapas de limpeza de dados, transformação de variáveis, análise de correlação e avaliação do modelo. O modelo obteve um coeficiente de determinação $R^2 = 0,61$, demonstrando poder preditivo moderado. Os resultados sugerem que variáveis como número de banheiros, presença de ar-condicionado e área construída exercem maior impacto no preço final dos imóveis.**

***Palavras-chave*—regressão linear, análise preditiva, preços de imóveis, aprendizado de máquina**

I. Introdução

A precificação de imóveis é uma tarefa complexa, influenciada por diversos fatores estruturais e ambientais. Modelos de aprendizado de máquina, como a regressão linear, têm sido amplamente utilizados para capturar essas relações e fornecer estimativas de preço com base em atributos observáveis.

O objetivo deste trabalho é aplicar técnicas de correlação e regressão linear a um conjunto de dados de preços de moradias, disponibilizado publicamente no Kaggle. Busca-se prever o valor dos imóveis a partir de variáveis como área construída, número de quartos e banheiros, proximidade da via principal da cidade, entre outros fatores, além de identificar aqueles que exercem maior influência no preço final de mercado.

II. Metodologia

A. Análise de Correlação

A correlação é uma medida estatística utilizada para avaliar a relação entre variáveis quantitativas. Foi construída uma matriz de correlação utilizando apenas os atributos numéricos do conjunto de dados, com o coeficiente de Pearson para mensurar o grau e a direção da relação linear.

Os valores obtidos foram representados graficamente em uma matriz de calor (*heatmap*) utilizando a biblioteca `Seaborn` no Python. Essa análise permite identificar relações fortes ou fracas entre variáveis e detectar possíveis problemas de multicolinearidade, que podem comprometer a qualidade do modelo de regressão linear.

B. Regressão Linear e Avaliação do Modelo

O modelo de regressão linear múltipla foi ajustado com base em sete variáveis explicativas:

- **area**: área total do imóvel (m²);
- **bedrooms**: número de quartos;
- **bathrooms**: número de banheiros;
- **stories**: número de pavimentos;
- **parking**: número de vagas de garagem;
- **airconditioning**: presença de ar-condicionado (variável binária);
- **prefarea**: localização em área preferencial (variável binária).

O modelo foi treinado utilizando a biblioteca `scikit-learn`, com avaliação por meio do Erro Quadrático Médio (MSE) e do coeficiente de determinação (R^2). Além disso, o impacto de cada variável no preço foi analisado pelos coeficientes estimados.

III. Resultados

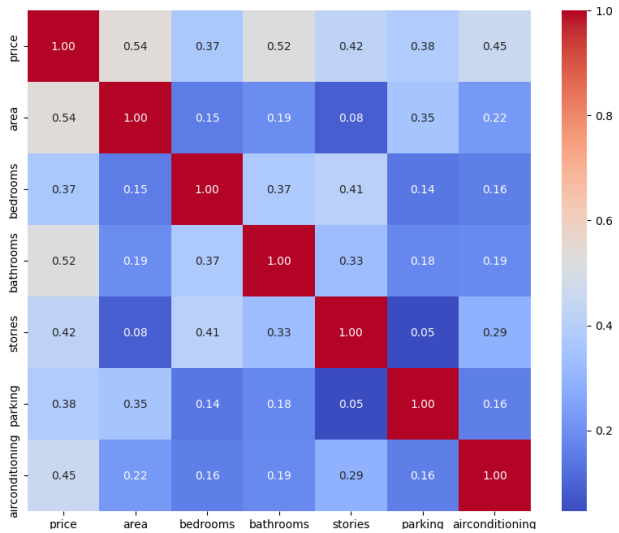

Fig. 1. Matriz de Correlação das Variáveis Numéricas.

Valores próximos de +1 indicam correlação linear positiva forte, enquanto valores próximos de -1 representam correlação linear negativa forte. Já valores próximos de 0 sugerem ausência de relação linear significativa. A análise da matriz de correlação (Figura 1) revela que o preço dos imóveis apresenta associação moderada com as variáveis analisadas, sendo mais influenciado pela área total, pelo número de banheiros e pela presença de ar-condicionado. Essas variáveis destacam-se como os principais determinantes do valor final de mercado.

TABLE I
COEFICIENTES ESTIMADOS PELO MODELO DE REGRESSÃO LINEAR.

Variável	Coeficiente (R$)	Interpretação
Intercepto	295.876,30	Valor base estimado sem variáveis explicativas
area	252,93	Cada m² adicional eleva o preço em R$ 252,93
bedrooms	102.998,52	Cada quarto adicional aumenta o preço médio
bathrooms	1.173.302,04	Cada banheiro adicional eleva o preço
stories	381.482,47	Cada pavimento adicional aumenta o preço
parking	272.991,99	Cada vaga de garagem acrescenta valor ao imóvel
airconditioning	844.621,03	A presença de ar-condicionado eleva o preço
prefarea	812.887,99	Localização em área preferencial aumenta o preço

Com base nos coeficientes estimados (Tabela I), foi possível gerar previsões de preço para os imóveis analisados. A Figura 2 apresenta a comparação entre os valores reais e os valores previstos pelo modelo, permitindo avaliar visualmente seu desempenho preditivo. Observa-se que, embora existam desvios pontuais, as previsões seguem uma tendência próxima aos valores observados, indicando boa capacidade de generalização do modelo.

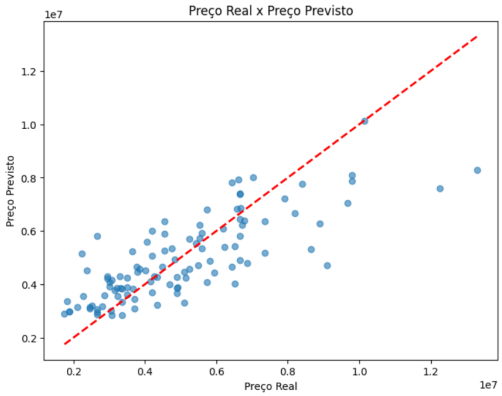

Fig. 2. Comparação entre preços reais e valores previstos pelo modelo de regressão linear.

O código-fonte utilizado neste estudo está disponível publicamente no repositório GitHub [7], possibilitando a reprodução e extensão dos resultados obtidos.

IV. DISCUSSÃO

Os resultados indicam que a presença de banheiros, ar-condicionado e localização preferencial exercem forte impacto sobre o preço dos imóveis. O coeficiente $R^2 = 0,61$ demonstra que o modelo captura parte significativa da variabilidade dos preços, mas ainda existem fatores não considerados, como proximidade a serviços, idade do imóvel e qualidade dos materiais.

V. CONCLUSÃO

A regressão linear mostrou-se eficaz para estimar preços de imóveis com base em variáveis estruturais. Recomenda-se incluir variáveis socioeconômicas e geográficas adicionais para melhorar a acurácia.

REFERÊNCIAS

[1] L. P. Fávero e P. Belfiore, *Manual de Análise de Dados: Estatística e Modelagem Multivariada com Excel®, SPSS® e Stata®*, 1ª ed. Rio de Janeiro, Brasil: Elsevier Editora Ltda., 2017. ISBN 978-85-352-7087-7.

[2] L. Igual e S. Seguí, *Introduction to Data Science: A Python Approach to Concepts, Techniques and Applications*, 2ª ed., Undergraduate Topics in Computer Science. Springer Nature Switzerland AG, 2024. ISBN 978-3-031-48955-6.

[3] GeeksforGeeks, "Multiple Linear Regression using Python - ML", 11 jul. 2025. [Online]. Disponível em: https://www.geeksforgeeks.org/machine-learning/ml-multiple-linear-regression-using-python/. Acesso em: 21 set. 2025.

[4] W3Schools, "Python Machine Learning Multiple Regression", 2025. [Online]. Disponível em: https://www.w3schools.com/Python/python_ml_multiple_regression.asp. Acesso em: 21 set. 2025.

[5] Hashtag Treinamentos, "O que é o Kaggle? Entenda e saiba como começar a usá-lo", 12 set. 2022. [Online]. Disponível em: https://www.hashtagtreinamentos.com/kaggle. Acesso em: 21 set. 2025.

[6] Acconcia, "Elaboração de TCCs", Medium, 8 ago. 2025. [Online]. Disponível em: https://acconcia.medium.com/elabora%C3%A7%C3%A3o-de-tccs-6d308b5fc7da. Acesso em: 21 set. 2025.

[7] L. F. Sampaio, "Código do estudo de regressão linear para previsão de preços de imóveis", GitHub repository, 2025. [Online]. Disponível em: https://github.com/LucasFortolan/PrevisaoValordeImovel-RegressaoLinear. Acesso em: 21 set. 2025.